TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN

VÕ XUÂN QUANG – 523H0173
HOÀNG XUÂN THÀNH – 523H0178

MÔ HÌNH HỎI ĐÁP Y TẾ

BÁO CÁO CUỐI KỲ
HỌC SÂU

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN

VÕ XUÂN QUANG – 523H0173
HOÀNG XUÂN THÀNH – 523H0178

MÔ HÌNH HỎI ĐÁP Y TẾ

BÁO CÁO CUỐI KỲ
HỌC SÂU

Người hướng dẫn
PGS. TS. LÊ ANH CƯỜNG
CN. DƯƠNG TRỌNG CHÍ

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026…

LỜI CẢM ƠN

Nhóm tác giả xin bày tỏ lòng biết ơn sâu sắc đến PGS. TS. Lê Anh Cường — giảng viên hướng dẫn trực tiếp của dự án — đã tận tình định hướng, góp ý kỹ thuật và mở rộng tầm nhìn của nhóm về những ứng dụng thực tiễn của Học sâu trong lĩnh vực y tế.

Những buổi thảo luận chuyên sâu cùng thầy đã giúp nhóm không chỉ hoàn thiện hệ thống về mặt kỹ thuật, mà còn nhận thức rõ hơn trách nhiệm của người xây dựng AI trong môi trường y khoa — nơi độ chính xác của mô hình có thể ảnh hưởng trực tiếp đến sức khỏe con người.

Nhóm cũng ghi nhận đóng góp quan trọng của cộng đồng nghiên cứu mở, đặc biệt là các tác giả của SLAKE, VQA-RAD, PhoBERT, TorchXRayVision và LLaVA-Med — những công trình tiên phong đã tạo nền tảng vững chắc cho dự án này. Mặc dù đã nỗ lực hết sức, báo cáo không tránh khỏi những thiếu sót. Nhóm rất mong nhận được ý kiến đóng góp từ hội đồng và bạn đọc để tiếp tục hoàn thiện.

TP. Hồ Chí Minh, ngày 4 tháng 5 năm 2026

Tác giả

(Ký tên và ghi rõ họ tên)

Quang

Võ Xuân Quang

Thành

Hoàng Xuân Thành

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH
TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Tôi xin cam đoan đây là công trình nghiên cứu của riêng tôi và được sự hướng dẫn khoa học của PGS. TS. Lê Anh Cường. Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong Dự án còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào tôi xin hoàn toàn chịu trách nhiệm về nội dung Dự án của mình. Trường Đại học Tôn Đức Thắng không liên quan đến những vi phạm tác quyền, bản quyền do tôi gây ra trong quá trình thực hiện (nếu có).

TP. Hồ Chí Minh, ngày 4 tháng 5 năm 2026

Tác giả

(Ký tên và ghi rõ họ tên)

TÓM TẮT

Báo cáo này trình bày quá trình xây dựng và đánh giá một hệ thống Hỏi đáp Trên Ảnh Y Khoa (Medical Visual Question Answering — Medical VQA) cho ngôn ngữ tiếng Việt. Hệ thống nhận đầu vào là một ảnh chẩn đoán hình ảnh (X-quang, MRI, CT) cùng một câu hỏi y khoa bằng tiếng Việt, và sinh ra câu trả lời ngắn gọn, chính xác về mặt lâm sàng.

Dữ liệu huấn luyện được xây dựng từ hai bộ dữ liệu y khoa quốc tế là SLAKE và VQA-RAD, được dịch sang tiếng Việt thông qua một pipeline dịch thuật tự động kết hợp từ điển y khoa chuyên ngành, tạo thành bộ dữ liệu gồm 6.711 cặp (ảnh, câu hỏi, câu trả lời).

Hệ thống được phát triển theo hai hướng tiếp cận song song. *Hướng A* là kiến trúc mô-đun kết hợp DenseNet-121 làm bộ mã hóa ảnh, PhoBERT làm bộ mã hóa câu hỏi, cơ chế co-attention để hợp nhất đặc trưng đa phương thức, và hai biến thể bộ giải mã — LSTM (A1) và Transformer Decoder (A2) — nhằm đánh giá so sánh có kiểm soát. *Hướng B* tinh chỉnh mô hình đa phương thức lớn LLaVA-Med 7B bằng kỹ thuật LoRA/QLoRA, bao gồm biến thể zero-shot (B1) và tinh chỉnh có giám sát (B2). Ngoài bốn cấu hình bắt buộc, hệ thống còn ứng dụng Direct Preference Optimization (DPO) và Proximal Policy Optimization (PPO) như những bước alignment để cải thiện chất lượng và tính y khoa của câu trả lời vượt ra ngoài giới hạn của học có giám sát thông thường.

Kết quả thực nghiệm cho thấy kiến trúc A2 đạt hiệu suất tốt nhất với độ chính xác 64,7%, F1 70,4%, BERTScore 91,7% và Closed Exact Match 77,8%. Đặc biệt, mô hình mô-đun A2 vượt trội hơn cả LLaVA-Med đã được tinh chỉnh (B2 — 60,2%), cho thấy với dữ liệu tiếng Việt y khoa có quy mô vừa, kiến trúc được thiết kế đặc thù có thể cạnh tranh trực tiếp với các mô hình lớn đa năng. Đánh giá định tính bởi người dùng xác nhận rằng DPO và PPO tạo ra những câu trả lời tự nhiên hơn và sử dụng thuật ngữ y khoa chính xác hơn so với học có giám sát đơn thuần.

Từ khóa: *Medical VQA, tiếng Việt, DenseNet-121, PhoBERT, co-attention, Transformer Decoder, LLaVA-Med, LoRA, DPO, PPO, BERTScore.*

MỤC LỤC

DANH MỤC CÁC BẢNG VÀ HÌNH ẢNH vii

DANH MỤC CÁC CHỮ VIẾT TẮT viii

CHƯƠNG 1. MỞ ĐẦU VÀ TỔNG QUAN ĐỀ TÀI 1

1.1 Bối cảnh và Động lực nghiên cứu 1

1.2 Phát biểu bài toán 1

1.3 Mục tiêu 2

1.4 Đóng góp chính 2

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT 3

2.1 Mô hình hỏi đáp trong Y khoa 3

2.2 Mạng tích chập dày đặc DenseNet-121 3

2.3 PhoBERT – Mô hình ngôn ngữ Tiếng Việt 4

2.4 Cơ chế Co - Attention 4

2.5 Transformer Decoder 5

2.6 LLaVA–Med – Mô hình Đa phương thức Y khoa 5

2.7 LoRA và QLoRA – Tinh chỉnh Hiệu quả Tham số 5

2.8 Alignment – DPO và PPO 6

2.9 Các Chỉ số Đánh giá 6

2.10 Model Soup – Trung bình Trọng số trong Không gian Tham số 7

CHƯƠNG 3. MÔ HÌNH ĐỀ XUẤT 8

3.1 Nguồn Dữ liệu gốc 8

3.2 Pipeline Dịch thuật sang Tiếng Việt 8

3.3 Thống kê Bộ dữ liệu 9

3.4 Preference Data cho Alignment 9

CHƯƠNG 4. KIẾN TRÚC MÔ HÌNH 10

4.1 Tổng quan Kiến trúc Hệ thống 10

4.2 Hướng A – Kiến trúc Mô – đun (A1 và A2) 10

4.2.1 Tổng quan 10

4.2.2 Bộ mã hoá ảnh – DenseNet – 121 10

4.2.3 Bộ mã hoá văn bản – PhoBERT 11

4.2.4 Co-Attention Fusion 11

4.2.5 Bộ giải mã – LSTM (A1) vs. Transformer (A2) 11

4.3 Hướng B – Kiến trúc Sinh Tự do (B1 và B2) 12

4.3.1 Tổng quan 12

4.4 Alignment – DPO và PPO 13

4.5 Model Soup – Trộn Trọng số Không Cần Huấn Luyện Lại 13

4.5.1 Tổng quan phương pháp 13

4.5.2 Áp dụng trong dự án – LoRA Adapter Soup 14

4.5.3 Lý do lựa chọn ba mô hình thành phần 15

4.5.4 Vị trí trong hệ thống 15

CHƯƠNG 5. TIỀN XỬ LÝ ẢNH VÀ TĂNG CƯỜNG DỮ LIỆU 16

5.1 Đặc thù của Ảnh Chẩn đoán Hình ảnh 16

5.2 Tiền xử lý Cơ bản 16

5.3 Chính sách Tăng cường Dữ liệu An toàn 17

CHƯƠNG 6. CHIẾN LƯỢC HUẤN LUYỆN 18

6.1 Huấn luyện Hướng A (A1/ A2) 18

6.2 Huấn luyện Hướng B (B1 / B2 / DPO / PPO) 19

CHƯƠNG 7. ĐÁNH GIÁ 20

7.1 Hệ thống Đánh giá Hạ tầng 20

7.2 Phân tách Đánh giá Đóng và Mở 20

7.2.1 Chỉ số cho câu hỏi đóng: 20

7.2.2 Chỉ số cho câu hỏi mở: 20

7.2.3 Chỉ số tổng hợp: 20

7.3 Đánh giá 21

CHƯƠNG 8. KẾT QUẢ THỰC NGHIỆM 22

8.1 Kết quả Định lượng Tổng hợp 22

8.2 Phân tích So sánh A1 vs. A2 - Ảnh hưởng của Bộ giải mã 23

8.3 Phân tích B1 vs. B2 – Hiệu quả của Fine – tuning 24

8.4 Phân tích DPO và PPO – Alignment vs. SFT 24

8.5 Phân tích Model Soup 25

8.6 Đường cong Hội tụ 25

CHƯƠNG 9. THẢO LUẬN 27

9.1 Tại sao Kiến trúc Mô-đun Vượt trội LLaVa-Med? 27

9.2 Hạn chế 28

9.3 Đề xuất Hướng Phát triển 28

CHƯƠNG 10. KẾT LUẬN 29

10.1 Tóm tắt 29

10.2 Ý nghĩa 29

TÀI LIỆU THAM KHẢO 30

DANH MỤC CÁC BẢNG VÀ HÌNH ẢNH

Bảng 3.1: Thống kê phân vùng dữ liệu Medical VQA tiếng Việt.....9

Bảng 3.2: *Phân phối loại câu hỏi trong bộ dữ liệu* 9

Bảng 4.1: Tổng quan kiến trúc hệ thống Medical VQA tiếng Việt 10

Bảng 4.2: Kiến trúc mô-đun Hướng A (A1/A2) 11

Bảng 4.3: Kiến trúc Hướng B dựa trên LLaVA-Med.....12

Bảng 4.4: Luồng alignment từ B2 đến DPO và PPO 13

Bảng 5.1: *Các phương thức tăng cường an toàn cho ảnh y khoa* 17

Bảng 5.2: *Các phương thức tăng cường không an toàn cho ảnh y khoa*.....17

Bảng 6.1: *Cấu hình huấn luyện Hướng A* 19

Bảng 8.1: *Kết quả so sánh sáu mô hình trên tập validation (best checkpoint).* 22

Bảng 8.2: So sánh bảy mô hình trên bảy chỉ số đánh giá chính......22

Bảng 8.3: Xếp hạng các mô hình theo val accuracy normalized (giảm dần)......23

Bảng 8.4: *So sánh chi tiết A1 vs. A2* 23

Bảng 8.5: So sánh SOUP với các mô hình thành phần và B2 25

Bảng 8.6: Val accuracy theo epoch của A1 (LSTM) và A2 (Transformer Decoder). 26

Bảng 9.1: Profile đa chiều của B2, A1, A2 và DPO trên tám chỉ số......27

DANH MỤC CÁC CHỮ VIẾT TẮT

VQA	Visual Question Answering (Hỏi đáp thị giác)
Medical VQA	Medical Visual Question Answering (Hỏi đáp thị giác y khoa)
MRI	Magnetic Resonance Imaging (Chụp cộng hưởng từ)
CT	Computed Tomography (Chụp cắt lớp vi tính)
X-ray	Chụp X-quang
LLM	Large Language Model (Mô hình ngôn ngữ lớn)
VLM	Vision-Language Model (Mô hình ngôn ngữ thị giác)
NLP	Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
BERT	Bidirectional Encoder Representations from Transformers
LoRA	Low-Rank Adaptation (Thích ứng hạng thấp)
QLoRA	Quantized Low-Rank Adaptation (LoRA lượng tử hóa)
DPO	Direct Preference Optimization (Tối ưu hóa ưu tiên trực tiếp)
PPO	Proximal Policy Optimization (Tối ưu hóa chính sách cận biên)
RLHF	Reinforcement Learning from Human Feedback (Học tăng cường từ phản hồi của con người)
SFT	Supervised Fine-Tuning (Tinh chỉnh có giám sát)
RAG	Retrieval-Augmented Generation (Sinh tăng cường tìm kiếm)
EM	Exact Match (Khớp chính xác)
BLEU	Bilingual Evaluation Understudy
ROUGE	Recall-Oriented Understudy for Gisting Evaluation
CLAHE	Contrast Limited Adaptive Histogram Equalization
GPU	Graphics Processing Unit (Đơn vị xử lý đồ họa)
AMP	Automatic Mixed Precision (Độ chính xác hỗn hợp tự động)

CHƯƠNG 1. MỞ ĐẦU VÀ TỔNG QUAN ĐỀ TÀI

1.1 Bối cảnh và Động lực nghiên cứu

Chẩn đoán hình ảnh y khoa — bao gồm X-quang, chụp cộng hưởng từ (MRI) và chụp cắt lớp vi tính (CT) — đóng vai trò trung tâm trong y học hiện đại. Các bác sĩ chẩn đoán hình ảnh phải giải thích những mẫu hình thị giác phức tạp và trả lời các câu hỏi lâm sàng đặc thù từ ảnh, thường trong điều kiện áp lực thời gian cao. Sự thiếu hụt bác sĩ chẩn đoán hình ảnh trên toàn cầu, đặc biệt tại các quốc gia đang phát triển như Việt Nam, cùng với tốc độ tăng trưởng vũ bão của dữ liệu hình ảnh y khoa, đã tạo ra nhu cầu cấp thiết cho các hệ thống hỗ trợ quyết định tự động.

Visual Question Answering (VQA) trong lĩnh vực y tế là bài toán cho phép hệ thống nhận đầu vào là một cặp (ảnh chẩn đoán, câu hỏi ngôn ngữ tự nhiên) và sinh ra câu trả lời có liên quan về mặt lâm sàng. Đây là một thách thức đa phương thức đòi hỏi đồng thời: (1) hiểu nội dung thị giác của ảnh y khoa, (2) hiểu ngữ nghĩa của câu hỏi trong ngữ cảnh y học, và (3) tổng hợp thông tin từ cả hai nguồn để suy luận câu trả lời. Độ phức tạp này khiến Medical VQA khác biệt căn bản so với phân loại ảnh hay nhận dạng đối tượng thông thường.

Trong bối cảnh tiếng Việt, thách thức càng trở nên rõ rệt. Tuyệt đại đa số hệ thống Medical VQA hiện có đều được thiết kế cho tiếng Anh. Các tài nguyên ngôn ngữ y khoa tiếng Việt — bộ dữ liệu, mô hình ngôn ngữ đặc thù, công cụ đánh giá — còn rất hạn chế. Điều này tạo ra khoảng cách đáng kể giữa tiến bộ nghiên cứu quốc tế và khả năng triển khai thực tế tại Việt Nam. Dự án này được thúc đẩy bởi mục tiêu thu hẹp khoảng cách đó.

1.2 Phát biểu bài toán

Cho một ảnh chẩn đoán hình ảnh I(X-quang, MRI hoặc CT) và một câu hỏi y khoa bằng tiếng Việt Q, hệ thống cần sinh ra câu trả lời ngắn gọn A(không vượt quá 10 từ) thỏa mãn đồng thời: (1) chính xác về mặt y khoa, (2) trung thành với nội dung ảnh, và (3) tự nhiên trong tiếng Việt.

Bài toán bao gồm hai loại câu hỏi:

- **Câu hỏi đóng:** Có đáp án thuộc tập hữu hạn, thường là Có/Không hoặc chọn từ danh mục cố định. Ví dụ: *"Ảnh có cho thấy tràn dịch màng phổi không?"*
- **Câu hỏi mở:** Yêu cầu sinh văn bản tự do mô tả đặc điểm lâm sàng. Ví dụ: *"Tổn thương xuất hiện ở vùng nào của phổi?"*

1.3 Mục tiêu

1. Xây dựng bộ dữ liệu Medical VQA tiếng Việt từ hai nguồn quốc tế SLAKE và VQA-RAD thông qua pipeline dịch thuật tự động kết hợp từ điển y khoa.
2. Thiết kế và huấn luyện kiến trúc mô-đun (Hướng A) với hai biến thể bộ giải mã để đánh giá có kiểm soát ảnh hưởng của kiến trúc đến hiệu suất.
3. Tinh chỉnh mô hình đa phương thức lớn LLaVA-Med (Hướng B) cho bài toán y khoa tiếng Việt.
4. Triển khai DPO và PPO như những cơ chế alignment để cải thiện chất lượng câu trả lời vượt ra ngoài giới hạn học có giám sát.
5. Xây dựng hệ thống đánh giá đa tầng kết hợp số liệu tự động, LLM-as-a-judge và đánh giá của con người.
6. Triển khai ứng dụng web cho phép so sánh trực quan tất cả sáu biến thể mô hình.

1.4 Đóng góp chính

- Đề xuất và đánh giá có hệ thống sáu biến thể mô hình Medical VQA tiếng Việt trong cùng một framework thống nhất — điều chưa từng được thực hiện trong bối cảnh tiếng Việt.
- Xây dựng pipeline dịch thuật kết hợp từ điển y khoa chuyên ngành, đảm bảo độ chính xác thuật ngữ khi chuyển đổi bộ dữ liệu quốc tế sang tiếng Việt.
- Trình bày phân tích so sánh toàn diện giữa kiến trúc mô-đun đặc thù và mô hình đa phương thức lớn đa năng trong điều kiện dữ liệu hạn chế.
- Đánh giá thực nghiệm đầu tiên về hiệu quả của DPO và PPO cho bài toán y khoa tiếng Việt, kết hợp cả đánh giá tự động và đánh giá định tính của con người.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1 Mô hình hỏi đáp trong Y khoa

Visual Question Answering (VQA) là bài toán giao thoa giữa Thị giác máy tính và Xử lý ngôn ngữ tự nhiên, yêu cầu hệ thống lý giải đồng thời nội dung ảnh và câu hỏi ngôn ngữ để sinh ra câu trả lời phù hợp. Trong lĩnh vực y tế, bài toán này có những đặc thù quan trọng so với VQA thông thường: ảnh y khoa chứa các đặc trưng tinh tế có thể không rõ ràng với mắt thường; câu trả lời đòi hỏi kiến thức chuyên sâu; và sai sót có thể dẫn đến hậu quả lâm sàng nghiêm trọng.

Các nghiên cứu tiên phong trong lĩnh vực này [8] cho thấy hai xu hướng kiến trúc chủ đạo: (1) kiến trúc mô-đun kết hợp bộ mã hóa ảnh riêng biệt với bộ mã hóa văn bản và cơ chế hợp nhất có học được; và (2) mô hình đa phương thức lớn được huấn luyện trước trên dữ liệu đa phương thức quy mô lớn rồi tinh chỉnh cho bài toán đích. Dự án này thực hiện so sánh trực tiếp giữa hai hướng trong cùng điều kiện dữ liệu.

2.2 Mạng tích chập dày đặc DenseNet-121

DenseNet (Densely Connected Convolutional Networks) [3] được đề xuất bởi Huang và cộng sự (2017) với đặc trưng kiến trúc nổi bật: mỗi tầng nhận đầu vào từ tất cả các tầng trước đó thay vì chỉ tầng liền kề. Kết nối dày đặc này tạo ra ba lợi thế quan trọng cho bài toán ảnh y khoa:

Bảo toàn đặc trưng cục bộ: Các đặc trưng hình thái học tinh tế như bờ tổn thương, mật độ mô, cấu trúc vi mạch — vốn rất quan trọng trong chẩn đoán nhưng có xu hướng bị suy giảm qua nhiều tầng tích chập thông thường — được bảo tồn tốt hơn nhờ các kết nối bỏ qua xuyên suốt.

Hiệu quả tham số: Tái sử dụng đặc trưng qua kết nối dày đặc giúp DenseNet đạt độ chính xác tương đương với mạng sâu hơn nhưng với số lượng tham số ít hơn đáng kể.

Luồng gradient ổn định: Gradient có thể lan truyền ngược trực tiếp từ đầu ra đến bất kỳ tầng nào, giảm thiểu vấn đề biến mất gradient khi huấn luyện trên tập dữ liệu y khoa có kích thước vừa.

Phiên bản DenseNet-121 được sử dụng trong dự án này có trọng số được tiền huấn luyện trên tập dữ liệu ảnh X-quang ngực quy mô lớn thông qua thư viện

TorchXRayVision, mang lại biểu diễn ban đầu phù hợp với đặc thù hình ảnh y khoa thay vì biểu diễn từ dữ liệu ảnh tự nhiên thông thường.

2.3 PhoBERT – Mô hình ngôn ngữ Tiếng Việt

PhoBERT [7] là mô hình ngôn ngữ học sâu dạng BERT được tiền huấn luyện trên kho ngữ liệu tiếng Việt 20GB, bao gồm văn bản từ Wikipedia tiếng Việt và nguồn tin tức. Điểm khác biệt cốt lõi so với các mô hình đa ngôn ngữ tổng quát như mBERT hay XLM-R là PhoBERT sử dụng tokenization dựa trên BPE (Byte-Pair Encoding) được tối ưu hóa riêng cho cấu trúc hình vị học tiếng Việt, xử lý tốt hơn các hiện tượng đặc trưng như dấu thanh điệu, phân tách âm tiết và ranh giới từ ghép.

Trong kiến trúc của dự án, PhoBERT mã hóa câu hỏi tiếng Việt thành chuỗi biểu diễn ngữ cảnh 768 chiều. Token đặc biệt [CLS] ở đầu chuỗi đóng vai trò biểu diễn mức câu và được sử dụng trong cơ chế co-attention, trong khi toàn bộ chuỗi token được sử dụng để tính attention cross-modal.

2.4 Cơ chế Co - Attention

Co-attention [6] là cơ chế hợp nhất đa phương thức cho phép học tương tác có điều kiện hai chiều giữa biểu diễn ảnh và văn bản. Thay vì đơn giản ghép nối (concatenation) hoặc tính trung bình (average pooling) đặc trưng từ hai nguồn, co-attention cho phép:

- **Hướng ảnh → văn bản:** Câu hỏi được làm nổi bật dựa trên những vùng không gian nào trong ảnh đang được quan tâm.
- **Hướng văn bản → ảnh:** Những vùng không gian trong ảnh được chú ý dựa trên những từ khóa nào trong câu hỏi mang ý nghĩa quan trọng nhất.

Về mặt hình thức, cho tập đặc trưng ảnh $V \in \mathbb{R}^{49\times1024}$(từ feature map 7×7 của DenseNet) và đặc trưng câu hỏi $Q \in \mathbb{R}^{L\times768}$, co-attention tính toán:

$$\text{Attention}(Q,K,V) = \text{softmax}\left(\frac{QW_Q\,(VW_K)^{\top}}{\sqrt{d_k}}\right)VW_V$$

trong đó W_Q, W_K, W_Vlà các ma trận chiếu được học, $d_k$là chiều của không gian key. Kết quả là biểu diễn hợp nhất đa phương thức phản ánh tương quan thực sự giữa nội dung ảnh và ngữ nghĩa câu hỏi.

2.5 Transformer Decoder

Transformer Decoder [5] mở rộng kiến trúc self-attention của Transformer với hai thành phần attention trong mỗi tầng:

- **Masked self-attention:** Cho phép mỗi token trong chuỗi đang sinh ra chú ý đến tất cả các token trước đó (causal masking), duy trì tính tự hồi quy trong quá trình sinh.
- **Cross-attention:** Cho phép chuỗi đang sinh chú ý lên toàn bộ biểu diễn hợp nhất đa phương thức từ co-attention, tích hợp thông tin ảnh-văn bản vào từng bước sinh.

Khả năng mô hình hóa phụ thuộc tầm xa trong một bước forward (không bị giới hạn bởi cấu trúc tuần tự của LSTM) là ưu điểm lý thuyết quan trọng nhất của Transformer so với LSTM, đặc biệt liên quan đến việc sinh câu trả lời mô tả y khoa có cấu trúc phức tạp.

2.6 LLaVA–Med – Mô hình Đa phương thức Y khoa

LLaVA-Med [10] là mô hình đa phương thức lớn được xây dựng từ kiến trúc LLaVA [9], kết hợp bộ mã hóa ảnh CLIP với mô hình ngôn ngữ Vicuna 7B thông qua một lớp chiếu tuyến tính. Điểm đặc biệt của LLaVA-Med là quá trình tiếp tục tiền huấn luyện (continued pretraining) trên các cặp ảnh-văn bản y khoa từ PubMed Central, tạo cho mô hình khả năng suy luận thị giác trong miền y khoa vượt trội so với các mô hình đa phương thức đa năng.

Trong bối cảnh tiếng Việt, LLaVA-Med gặp thách thức cơ bản: toàn bộ quá trình tiền huấn luyện được thực hiện trên ngữ liệu tiếng Anh, khiến mô hình không thể xử lý câu hỏi tiếng Việt một cách hiệu quả nếu không có bước thích ứng. Dự án này giải quyết thách thức đó thông qua tinh chỉnh có giám sát trên dữ liệu tiếng Việt sử dụng LoRA và QLoRA.

2.7 LoRA và QLoRA – Tinh chỉnh Hiệu quả Tham số

LoRA (Low-Rank Adaptation) [11] là phương pháp tinh chỉnh hiệu quả tham số cho mô hình lớn, hoạt động bằng cách chèn các ma trận rank thấp $\Delta W = BA$vào các tầng attention, với $B \in \mathbb{R}^{d\times r}$và $A \in \mathbb{R}^{r\times k}$, $r \ll \min(d, k)$. Trong quá trình tinh chỉnh, trọng số gốc W_0được đóng băng; chỉ Avà Bđược cập nhật. Điều này giảm số tham số cần huấn luyện xuống dưới 1% so với tinh chỉnh toàn phần trong khi vẫn đạt hiệu suất cạnh tranh.

QLoRA [12] mở rộng LoRA bằng cách kết hợp lượng tử hóa 4-bit (NF4 — Normal Float 4) cho trọng số gốc đã đóng băng, cùng với lượng tử hóa kép (double quantization) để nén thêm hằng số lượng tử hóa. Kết quả là bộ nhớ GPU cần thiết để tinh chỉnh LLaVA-Med 7B giảm từ xấp xỉ 28GB (tinh chỉnh toàn phần) xuống dưới 8GB, phù hợp với GPU thông dụng.

2.8 Alignment – DPO và PPO

DPO (Direct Preference Optimization) [13] giải quyết bài toán alignment từ preference data mà không cần huấn luyện reward model riêng biệt. Cho mỗi prompt xvới cặp câu trả lời y_w(được ưa thích) và y_l(bị loại bỏ), DPO tối ưu hàm mất mát:

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E}\left[\log \sigma\left(\beta \log \frac{\pi_\theta(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta \log \frac{\pi_\theta(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)}\right)\right]$$

trong đó π_{ref}là mô hình tham chiếu đóng băng và βkiểm soát mức độ lệch khỏi tham chiếu. DPO ổn định hơn PPO về mặt động lực huấn luyện vì loại bỏ vòng lặp actor-critic phức tạp.

PPO (Proximal Policy Optimization) [14] sử dụng một hàm phần thưởng $r(x, y)$để cập nhật policy trong biên độ kiểm soát bằng mục tiêu clipped surrogate:

$$\mathcal{L}_{\text{PPO}} = -\mathbb{E}[\min(\rho_t A_t, \text{clip}(\rho_t, 1-\epsilon, 1+\epsilon) A_t)]$$

trong đó $\rho_t = \pi_\theta(a_t \mid s_t)/\pi_{\text{old}}(a_t \mid s_t)$là tỉ lệ xác suất giữa policy mới và cũ, và $A_t$là advantage estimate. Trong dự án này, hàm phần thưởng được tính tổ hợp từ VQA Accuracy và BERTScore, thưởng cho những câu trả lời vừa chính xác về mặt nhãn vừa gần nghĩa với đáp án chuẩn.

2.9 Các Chỉ số Đánh giá

Hệ thống đánh giá sử dụng năm nhóm chỉ số bổ sung lẫn nhau. **Exact Match (EM)** kiểm tra sự khớp chuỗi chính xác sau chuẩn hóa (chữ thường, loại dấu câu), là chỉ số cơ bản nhất cho câu hỏi đóng. **F1 mức token** tính trung bình điều hòa của precision và recall ở mức token, phù hợp hơn EM khi câu trả lời có thể diễn đạt theo nhiều cách. **BLEU** [8] đo mức độ trùng khớp n-gram có trọng số, trong đó BLEU-4 là chuẩn thực tiễn cho đánh giá sinh văn bản. **ROUGE-L** đo độ dài của subsequence

chung dài nhất, phù hợp với câu trả lời mở có thứ tự từ quan trọng. **BERTScore** [15] tính tương đồng cosine giữa embedding của câu trả lời sinh ra và đáp án chuẩn từ mô hình BERT tiền huấn luyện — đây là chỉ số gần nhất với đánh giá ngữ nghĩa thực sự, ít bị ảnh hưởng bởi sự khác biệt từ ngữ bề mặt.

2.10 Model Soup – Trung bình Trọng số trong Không gian Tham số

Model Soup được giới thiệu bởi Wortsman và cộng sự (2022) [17] dựa trên quan sát rằng các mô hình được fine-tune từ cùng một checkpoint tiền huấn luyện thường hội tụ về các điểm lân cận nhau trong một vùng phẳng (flat basin) của bề mặt loss. Trong vùng phẳng này, trung bình trọng số giữa các mô hình thường cho điểm loss thấp hơn hoặc bằng bất kỳ mô hình đơn lẻ nào — điều này trái với trực giác thông thường khi áp dụng trong không gian tham số phi lồi.

Phương pháp có ba yêu cầu cơ bản để hoạt động hiệu quả: (1) các mô hình thành phần phải cùng xuất phát từ một điểm khởi tạo; (2) không gian tham số phải đủ "phẳng" tại vùng hội tụ; và (3) các mô hình thành phần nên đại diện cho các hướng tối ưu khác nhau nhưng không quá xa nhau trong không gian tham số. Cả ba điều kiện đều được thỏa mãn trong trường hợp SOUP của dự án này: B2, DPO và PPO cùng xuất phát từ backbone LLaVA-Med, được fine-tune trên cùng phân phối dữ liệu, và sử dụng cùng kiến trúc LoRA.

CHƯƠNG 3. MÔ HÌNH ĐỀ XUẤT

3.1 Nguồn Dữ liệu gốc

SLAKE (Structured Language and Knowledge-Enhanced) [1] là bộ dữ liệu VQA y khoa đa ngôn ngữ (Anh–Trung) với các chú thích ngữ nghĩa phong phú bao gồm liên kết đồ thị tri thức. SLAKE bao phủ ảnh từ nhiều phương thức chẩn đoán — X-quang, MRI não, CT bụng — với câu hỏi đa dạng về loại tổn thương, vị trí giải phẫu, thuộc tính ảnh và phương thức chụp.

VQA-RAD [2] là bộ dữ liệu được xây dựng bởi các chuyên gia y tế tại Viện Sức khỏe Quốc gia Hoa Kỳ (NIH), bao gồm các câu hỏi phản ánh nhu cầu thông tin lâm sàng thực tế khi đọc ảnh X-quang ngực, đầu và bụng. Tính lâm sàng cao của VQA-RAD giúp đánh giá khả năng thực tiễn của mô hình trong môi trường bệnh viện.

3.2 Pipeline Dịch thuật sang Tiếng Việt

Quá trình chuyển đổi dữ liệu từ tiếng Anh sang tiếng Việt là một trong những đóng góp kỹ thuật quan trọng của dự án. Pipeline được thiết kế theo quy trình sáu bước để đảm bảo chất lượng ngôn ngữ và độ chính xác y khoa:

Bước 1 — Chuẩn hóa đầu vào: Loại bỏ ký tự đặc biệt, chuẩn hóa định dạng câu hỏi và câu trả lời về dạng thống nhất, loại bỏ các mục trùng lặp.

Bước 2 — Dịch thuật tăng cường từ điển: Áp dụng từ điển y khoa chuyên ngành Anh–Việt để ánh xạ các thuật ngữ y tế trước khi dịch máy, đảm bảo những từ như *pleural effusion* luôn được dịch nhất quán là *tràn dịch màng phổi* thay vì bị dịch máy diễn giải tùy tiện. Phương pháp này theo hướng tiếp cận của nghiên cứu [16] về dictionary-enhanced prompting cho dịch thuật miền chuyên ngành.

Bước 3 — Hậu xử lý ngôn ngữ: Chuẩn hóa dấu câu tiếng Việt, kiểm tra và sửa lỗi dấu thanh điệu, canonicalize các thuật ngữ y khoa theo chuẩn tiếng Việt.

Bước 4 — Gắn nhãn và phân loại: Mỗi mẫu được gắn nhãn loại câu hỏi (đóng/mở) và danh mục (nhận dạng bất thường, xác định cơ quan, mô tả thuộc tính, phương thức chụp, quan hệ không gian).

Bước 5 — Kiểm tra chất lượng: Kiểm tra ngẫu nhiên thủ công kết hợp đánh giá bằng LLM để phát hiện các bản dịch sai hoặc không tự nhiên.

Bước 6 — Phân chia dữ liệu: Chia stratified theo loại câu hỏi và nguồn gốc dữ liệu để đảm bảo phân phối cân bằng trong cả ba phân vùng.

3.3 Thống kê Bộ dữ liệu

Sau toàn bộ quá trình xử lý, bộ dữ liệu Medical VQA tiếng Việt có các thống kê sau:

Phân vùng	Số mẫu	Tỉ lệ
Tập huấn luyện (Train)	5.370	80%
Tập kiểm định (Validation)	671	10%
Tập kiểm thử (Test)	672	10%
Tập kiểm thử thủ công	50	bổ sung
Tổng cộng	**6.763**	

Bảng 3.1: Thống kê phân vùng dữ liệu Medical VQA tiếng Việt

Phân phối loại câu hỏi trong toàn bộ tập dữ liệu:

Loại câu hỏi	Số lượng	Tỉ lệ
Câu hỏi đóng (Có/Không)	3.124	46,5%
Câu hỏi mở — Nhận dạng bất thường	1.287	19,2%
Câu hỏi mở — Xác định cơ quan/vị trí	1.102	16,4%
Câu hỏi mở — Mô tả thuộc tính	854	12,7%
Câu hỏi mở — Phương thức/Không gian	396	5,9%

Bảng 3.2: *Phân phối loại câu hỏi trong bộ dữ liệu*

3.4 Preference Data cho Alignment

Để hỗ trợ DPO và PPO, 120 cặp preference data (chosen, rejected) được xây dựng bằng cách lấy mẫu đầu ra từ nhiều checkpoint khác nhau cho cùng một câu hỏi, sau đó xếp hạng theo tổ hợp BERTScore, VQA Accuracy và đánh giá thủ công. Các cặp chosen là câu trả lời vừa chính xác về nhãn, vừa tự nhiên về ngôn ngữ và phù hợp y khoa; các cặp rejected bao gồm câu trả lời sai hoàn toàn, quá mơ hồ, hoặc sử dụng sai thuật ngữ chuyên ngành.

CHƯƠNG 4. KIẾN TRÚC MÔ HÌNH

4.1 Tổng quan Kiến trúc Hệ thống

Hệ thống được tổ chức theo hai hướng tiếp cận song song nhưng dùng chung pipeline dữ liệu và framework đánh giá. Sơ đồ tổng quát:

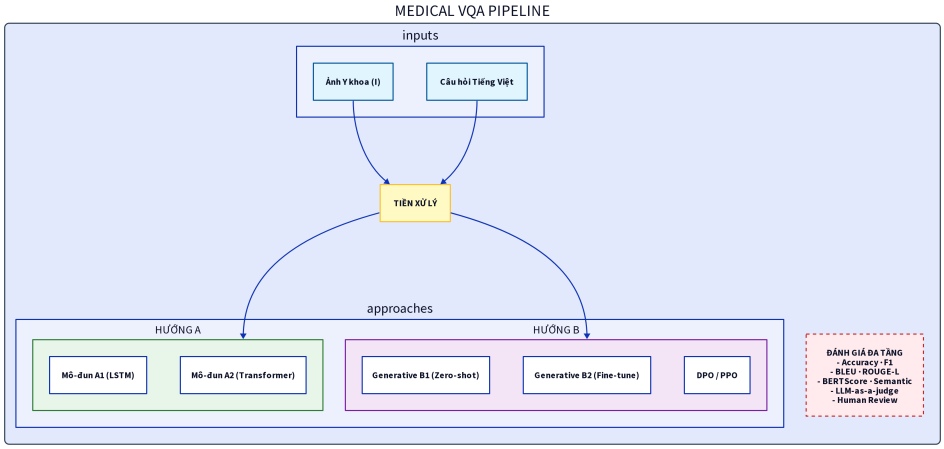

Bảng 4.1: Tổng quan kiến trúc hệ thống Medical VQA tiếng Việt

4.2 Hướng A – Kiến trúc Mô – đun (A1 và A2)

4.2.1 Tổng quan

Kiến trúc mô-đun được thiết kế để kiểm soát chặt chẽ từng thành phần, cho phép thực nghiệm so sánh có tính hệ thống. Toàn bộ pipeline gồm bốn giai đoạn nối tiếp: mã hóa ảnh, mã hóa văn bản, hợp nhất đa phương thức, và giải mã câu trả lời.

4.2.2 Bộ mã hoá ảnh – DenseNet – 121

DenseNet-121 nhận ảnh y khoa đã được tiền xử lý (kích thước chuẩn, 1 kênh grayscale, chuẩn hóa theo phân phối X-quang) và tạo ra feature map không gian kích

thước 7×7×1024. Feature map này giữ lại thông tin vị trí không gian — quan trọng cho các câu hỏi về vị trí tổn thương — thay vì đơn giản hóa thành vector toàn cục.

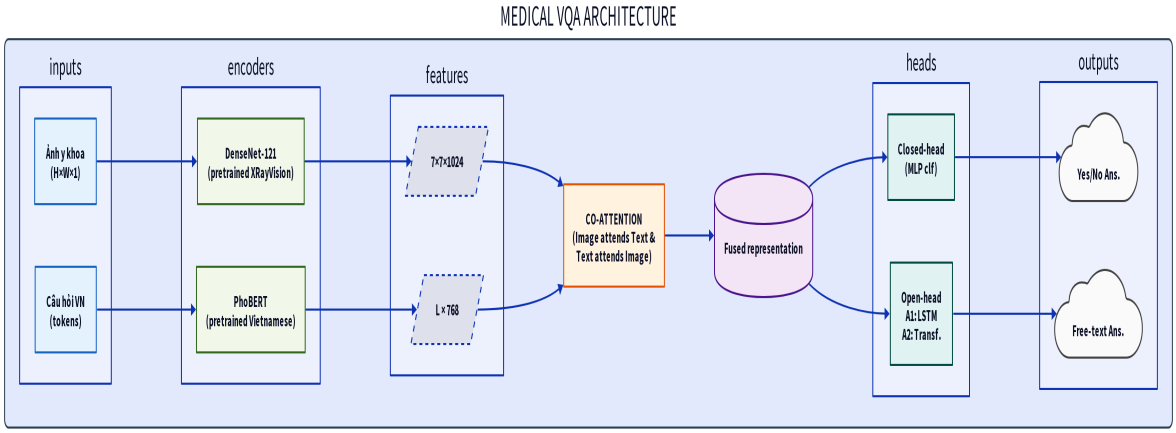

Bảng 4.2: Kiến trúc mô-đun Hướng A (A1/A2)

4.2.3 Bộ mã hoá văn bản – PhoBERT

PhoBERT tokenize câu hỏi tiếng Việt bằng BPE tokenizer và tạo ra chuỗi L biểu diễn ngữ cảnh 768 chiều. Trong khi vector [CLS] đại diện cho ngữ nghĩa cấp câu, toàn bộ chuỗi token được sử dụng để tính co-attention, đảm bảo không mất thông tin ngữ nghĩa cục bộ của từng từ khóa quan trọng.

4.2.4 Co-Attention Fusion

Lớp co-attention học tương tác có điều kiện hai chiều: câu hỏi quyết định vùng nào của ảnh cần chú ý, và ngược lại. Biểu diễn hợp nhất đầu ra có chiều tương thích với cả hai nhánh giải mã, đảm bảo thông tin ảnh-văn bản được tích hợp đầy đủ.

4.2.5 Bộ giải mã – LSTM (A1) vs. Transformer (A2)

A1 — LSTM Decoder: Bộ giải mã LSTM nhiều lớp sinh câu trả lời token-by-token trong khi duy trì trạng thái ẩn mang ngữ cảnh của các token đã sinh. Ưu điểm là đơn giản, ổn định khi huấn luyện trên tập dữ liệu nhỏ; nhược điểm là phụ thuộc xa bị suy giảm theo chiều dài chuỗi.

A2 — Transformer Decoder: Mỗi tầng Transformer Decoder bao gồm masked self-attention (chú ý đến toàn bộ các token đã sinh trong một bước, không bị suy giảm theo khoảng cách), cross-attention lên biểu diễn hợp nhất đa phương thức, và feed-forward network. Các kỹ thuật kỹ thuật quan trọng được áp dụng: chia sẻ trọng số giữa lớp embedding đầu vào và lớp chiếu đầu ra (weight tying) để giảm tham số và tăng tính nhất quán biểu diễn; beam search với length normalization ($\alpha = 0{,}7$) để tránh thiên lệch về câu trả lời ngắn.

4.3 Hướng B – Kiến trúc Sinh Tự do (B1 và B2)

4.3.1 Tổng quan

Hướng B sử dụng LLaVA-Med 7B — mô hình đa phương thức lớn được tiền huấn luyện trước trên dữ liệu y khoa — như nền tảng. Kiến trúc được triển khai với 4-bit quantization và LoRA adapters để giảm yêu cầu bộ nhớ GPU.

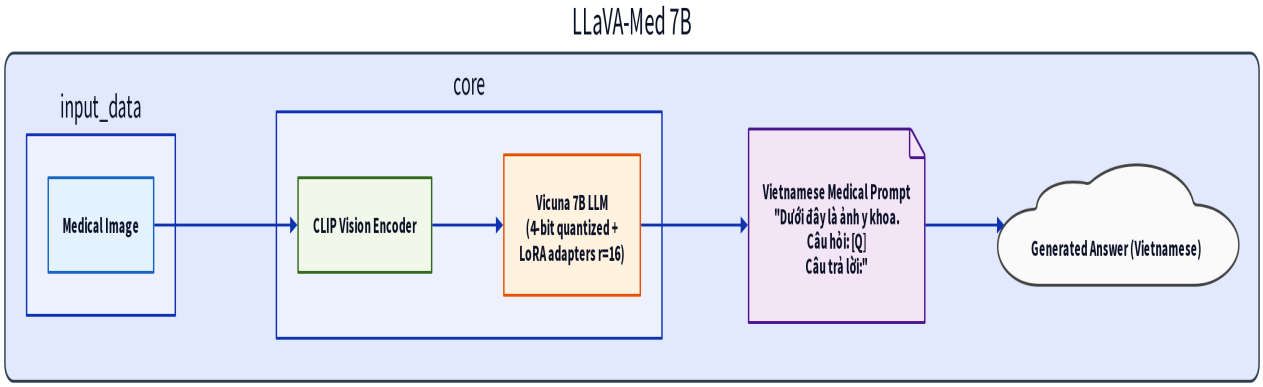

Bảng 4.3: Kiến trúc Hướng B dựa trên LLaVA-Med

B1 (Zero-shot): LLaVA-Med được truy vấn trực tiếp với prompt tiếng Việt đã được thiết kế cẩn thận, không thực hiện bất kỳ cập nhật tham số nào. Đây là đường cơ sở để đánh giá khả năng chuyển giao zero-shot của mô hình sang tiếng Việt.

B2 (Fine-tuned SFT): Các LoRA adapters (rank 16, alpha 32) được huấn luyện trên tập dữ liệu tiếng Việt theo mục tiêu dự đoán token tiếp theo (next-token prediction), với ảnh và câu hỏi là prefix context và câu trả lời là chuỗi cần sinh.

4.4 Alignment – DPO và PPO

Hai phương pháp alignment được ứng dụng như những bước tinh chỉnh bổ sung từ checkpoint B2, hướng đến việc cải thiện chất lượng câu trả lời theo chiều mà học có giám sát đơn thuần không thể nắm bắt được.

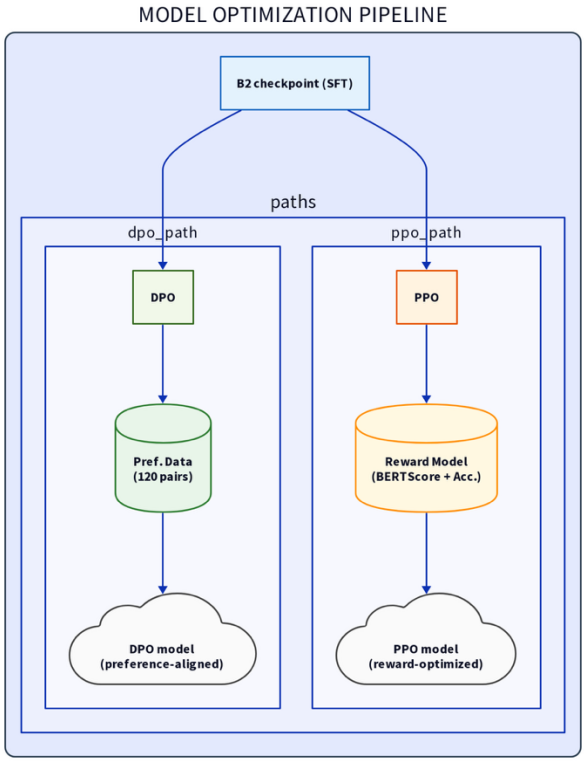

Bảng 4.4: Luồng alignment từ B2 đến DPO và PPO

4.5 Model Soup – Trộn Trọng số Không Cần Huấn Luyện Lại

4.5.1 Tổng quan phương pháp

Model Soup là kỹ thuật kết hợp trọng số của nhiều mô hình đã được fine-tune độc lập để tạo ra một mô hình mới mà không cần bất kỳ vòng lặp huấn luyện bổ sung nào. Xuất phát từ quan sát rằng các mô hình được fine-tune từ cùng một điểm khởi đầu thường hội tụ

về các vùng lân cận trong không gian tham số, việc lấy trung bình trọng số giữa các mô hình này có xu hướng tìm ra điểm có loss thấp hơn bất kỳ mô hình đơn lẻ nào — một hiện tượng được gọi là *loss basin flatness*.

Hình thức tổng quát của Model Soup là trung bình số học (uniform soup) của ktập tham số $\{\theta_1, \theta_2, \dots, \theta_k\}$:

$$\theta_{\text{soup}} = \frac{1}{k}\sum_{i=1}^{k}\theta_i$$

Đây là phương pháp không cần dữ liệu mới, không cần huấn luyện lại, và không phát sinh chi phí tính toán lớn — những đặc điểm đặc biệt phù hợp khi tài nguyên tính toán bị giới hạn.

4.5.2 Áp dụng trong dự án – LoRA Adapter Soup

Trong hệ thống Medical VQA tiếng Việt, Model Soup được xây dựng bằng cách trộn trọng số của ba LoRA adapter tương ứng với ba mô hình B2, DPO và PPO — tất cả đều xuất phát từ cùng backbone LLaVA-Med 7B nhưng được tối ưu theo các chiến lược khác nhau:

Cụ thể, mỗi LoRA adapter gồm các cặp ma trận (A_i, B_i)được chèn vào các lớp attention. Quá trình tạo SOUP thực hiện trung bình số học trên từng cặp ma trận tương ứng:

$$A_{\text{soup}} = \frac{1}{3}(A_{B2} + A_{\text{DPO}} + A_{\text{PPO}})$$

$$B_{\text{soup}} = \frac{1}{3}(B_{B2} + B_{\text{DPO}} + B_{\text{PPO}})$$

Adapter SOUP sau đó được lưu thành file độc lập và nạp vào cùng backbone LLaVA-Med để suy luận — quy trình triển khai hoàn toàn giống với B2, DPO và PPO, không phát sinh thêm overhead.

4.5.3 Lý do lựa chọn ba mô hình thành phần

Ba mô hình được chọn vì mỗi mô hình đại diện cho một chiến lược tối ưu khác nhau, bổ sung lẫn nhau:

- **B2** mang tri thức từ học có giám sát thuần túy — học tốt phân phối dữ liệu Medical VQA tiếng Việt, nhưng bị ràng buộc bởi những gì có trong tập huấn luyện.
- **DPO** điều chỉnh mô hình theo preference của con người — cải thiện tính tự nhiên và chuẩn mực y khoa của câu trả lời, nhưng có thể hy sinh một phần exact-match accuracy.
- **PPO** tối ưu theo tín hiệu phần thưởng tổng hợp — cân bằng giữa chính xác nhãn (VQA Accuracy) và gần nghĩa (BERTScore), nhưng phụ thuộc vào chất lượng của hàm phần thưởng được thiết kế.

Việc trộn trọng số ba adapter này kỳ vọng tạo ra một checkpoint trung gian tận dụng đồng thời ưu điểm của cả ba hướng tối ưu, trong khi làm mịn (smooth out) các thiên lệch cực đoan mà mỗi mô hình đơn lẻ có thể mang theo.

4.5.4 Vị trí trong hệ thống

SOUP được xem là biến thể mô hình thứ bảy trong hệ thống, bổ sung vào sáu cấu hình chính (A1, A2, B1, B2, DPO, PPO). Vì backbone và kiến trúc suy luận hoàn toàn giống B2/DPO/PPO, SOUP không phát sinh thêm chi phí bộ nhớ hay thời gian inference đáng kể so với các mô hình Hướng B khác.

CHƯƠNG 5. TIỀN XỬ LÝ ẢNH VÀ TĂNG CƯỜNG DỮ LIỆU

5.1 Đặc thù của Ảnh Chẩn đoán Hình ảnh

Ảnh y khoa khác biệt căn bản so với ảnh tự nhiên ở một số khía cạnh quan trọng về mặt kỹ thuật tăng cường dữ liệu. Trong ảnh tự nhiên, một con chó xoay 90° vẫn là con chó; nhưng trong ảnh X-quang, một ảnh phổi xoay 90° có thể khiến bệnh lý xuất hiện ở vị trí giải phẫu sai, tạo ra các mẫu hình học được mà mô hình không nên học. Điều này đặt ra yêu cầu nghiêm ngặt: mọi thao tác tiền xử lý và tăng cường dữ liệu đều phải có giá trị lâm sàng hợp lệ — chỉ mô phỏng các biến thể thực sự xảy ra trong quá trình chụp ảnh, không tạo ra ảnh giải phẫu phi thực tế.

5.2 Tiền xử lý Cơ bản

Resize và chuẩn hóa kích thước: Ảnh đầu vào được đưa về kích thước chuẩn tương thích với DenseNet-121 (224×224 pixels), sử dụng nội suy bilinear để bảo toàn thông tin chi tiết tối đa.

CLAHE (Contrast Limited Adaptive Histogram Equalization): Đây là bước tiền xử lý quan trọng nhất đối với ảnh X-quang và CT. Khác với histogram equalization toàn cục có thể khuếch đại nhiễu và làm mất chi tiết trong các vùng sáng đồng đều, CLAHE phân chia ảnh thành các ô nhỏ (tiles) và thực hiện cân bằng histogram cục bộ trong từng ô, đồng thời giới hạn mức khuếch đại tương phản để tránh nhiễu. Kết quả là các đặc trưng tinh tế như bờ tổn thương, cấu trúc mạch máu nhỏ và vùng thâm nhiễm sớm được làm rõ mà không hy sinh chất lượng ảnh tổng thể.

Normalization theo chuẩn TorchXRayVision: Giá trị pixel được chuẩn hóa về phân phối phù hợp với trọng số tiền huấn luyện của DenseNet-121 trên dữ liệu X-quang, thay vì dùng chuẩn hóa ImageNet thông thường — vốn không phù hợp cho ảnh grayscale y khoa.

5.3 Chính sách Tăng cường Dữ liệu An toàn

Các phương thức tăng cường dữ liệu trong ảnh y khoa được phân loại thành an toàn và không an toàn dựa trên tiêu chí lâm sàng:

Tăng cường AN TOÀN (được phép):

Phương thức	Phạm vi An toàn	Lý do Lâm sàng
Điều chỉnh độ sáng	±10–15%	Mô phỏng biến thể thiết bị chụp
Điều chỉnh tương phản	±15%	Biến thể phơi sáng thực tế
Nhiễu Gaussian	$\sigma \leq 1\%$	Mô phỏng nhiễu cảm biến
Xoay nhỏ	±2–3° tối đa	Chỉ sai số định vị bệnh nhân
Zoom nhỏ	±2–3%	Biến thể tiêu cự nhỏ
Làm mờ Gaussian	$\sigma \leq 0{,}3$	Mô phỏng artifact chuyển động

Bảng 5.1: *Các phương thức tăng cường an toàn cho ảnh y khoa*

Tăng cường KHÔNG AN TOÀN (bị cấm):

Phương thức	Lý do Không an toàn	Nguy cơ Lâm sàng
Lật ngang (horizontal flip)	PA ≠ AP — hai góc chụp khác nhau về mặt chẩn đoán	Nhầm lẫn định hướng giải phẫu
Xoay lớn (> 5°)	Thay đổi vị trí tổn thương so với mốc giải phẫu	Mô hình học mẫu hình sai
Lật dọc (vertical flip)	Đảo ngược toàn bộ giải phẫu	Tạo ảnh phi thực tế hoàn toàn
Xóa ngẫu nhiên (random erasing)	Có thể che khuất tổn thương	Mô hình học bỏ qua vùng bệnh lý
Biến dạng đàn hồi mạnh	Biến dạng cấu trúc giải phẫu	Làm mờ ranh giới tổn thương
Lật dọc	Đảo ngược trên/dưới	Ảnh phi thực tế

Bảng 5.2: *Các phương thức tăng cường không an toàn cho ảnh y khoa*

Lý do cốt lõi của phân biệt này: Trong ảnh y khoa, *định hướng* và *vị trí không gian* mang thông tin chẩn đoán. Một ảnh X-quang phổi chụp góc PA (Posterior-Anterior) và góc AP (Anterior-Posterior) cho dù trông gần giống nhau nhưng có ý nghĩa chẩn đoán khác nhau. Xoay ảnh 10° có thể khiến vùng phổi tổn thương xuất hiện ở vị trí sai so với các mốc giải phẫu chuẩn, hoặc làm cho đường gãy xương không nhìn thấy được từ góc nhìn đã bị xoay. Mô hình được huấn luyện trên ảnh có augmentation không an toàn sẽ học các mẫu hình sai và có thể đưa ra khuyến nghị không chính xác khi triển khai lâm sàng.

CHƯƠNG 6. CHIẾN LƯỢC HUẤN LUYỆN

6.1 Huấn luyện Hướng A (A1/ A2)

Vòng lặp huấn luyện cho kiến trúc mô-đun áp dụng một số kỹ thuật tối ưu hóa:

AMP (Automatic Mixed Precision): Sử dụng float16 cho các phép tính phù hợp (forward pass, hầu hết các phép nhân ma trận) trong khi giữ float32 cho master weights và loss scaling. Điều này tăng tốc huấn luyện 1,5–2× và giảm bộ nhớ GPU mà không hy sinh độ chính xác số học.

Gradient Accumulation: Mô phỏng batch size lớn hơn trên GPU hạn chế bộ nhớ bằng cách tích lũy gradient qua nhiều mini-batch trước khi cập nhật tham số.

Hàm mất mát hai nhánh: Loss tổng được tính tổ hợp từ hai thành phần:

$$\mathcal{L}_{\text{total}} = \lambda_c \cdot \mathcal{L}_{\text{closed}} + \lambda_o \cdot \mathcal{L}_{\text{open}}$$

trong đó $\mathcal{L}_{\text{closed}}$là cross-entropy cho câu hỏi đóng với trọng số lớp động (dynamic class weights) để cân bằng phân phối Yes/No lệch; $\mathcal{L}_{\text{open}}$là cross-entropy cho sinh chuỗi kèm brevity penalty để tránh mô hình thoái hóa về chỉ sinh một token.

Label smoothing ($\varepsilon = 0{,}1$) trên nhánh mở: Làm mềm phân phối mục tiêu, giảm overconfidence và cải thiện khả năng tổng quát hóa trên câu trả lời mở y khoa có nhiều cách diễn đạt hợp lệ.

Cosine Annealing với Linear Warmup: Learning rate tăng tuyến tính trong 5% đầu tổng số bước, sau đó giảm theo hàm cosine về giá trị tối thiểu. Warmup giúp ổn định giai đoạn đầu huấn luyện khi các lớp randomly initialized chưa cân bằng với các lớp pretrained.

Early Stopping: Huấn luyện dừng khi validation accuracy không cải thiện trong một số epoch liên tiếp (patience window), tránh overfitting và tiết kiệm thời gian tính toán.

Siêu tham số	A1	A2
Số epoch tối đa	50	50
Epoch thực tế (best checkpoint)	41	32
Batch size hiệu dụng	32	32
Learning rate ban đầu	3e-4	3e-4
Warmup ratio	5%	5%
Label smoothing	0,1	0,1
Beam width (inference)	4	4

Bảng 6.1: *Cấu hình huấn luyện Hướng A*

6.2 Huấn luyện Hướng B (B1 / B2 / DPO / PPO)

B2 — Supervised Fine-Tuning: LoRA adapters (rank 16, alpha 32, dropout 0,05) được chèn vào các lớp attention projection (q_proj, v_proj, k_proj, o_proj) của Vicuna backbone. Chỉ các adapters này được cập nhật trong quá trình huấn luyện; toàn bộ trọng số gốc và vision encoder CLIP được đóng băng. Tổng tham số được huấn luyện: ~42M (so với 7B tổng, tương đương ~0,6%).

DPO: Sử dụng B2 làm cả policy khởi đầu lẫn reference model đóng băng. Tham số $\beta = 0{,}1$kiểm soát mức độ lệch khỏi reference. Huấn luyện 3 epoch trên 120 preference pairs với learning rate 1e-5.

PPO: Hàm phần thưởng tổ hợp: $r = 0{,}5 \times \text{VQA_Accuracy} + 0{,}5 \times \text{BERTScore}$. PPO-clip với $\varepsilon = 0{,}2$; KL penalty coefficient 0,01 so với B2 reference để tránh reward hacking.

CHƯƠNG 7. ĐÁNH GIÁ

7.1 Hệ thống Đánh giá Hạ tầng

Đặc thù của bài toán Medical VQA tiếng Việt đòi hỏi một hệ thống đánh giá đa tầng: câu hỏi đóng cần so khớp nhãn chuẩn chính xác, trong khi câu hỏi mở có nhiều diễn đạt hợp lệ cho cùng một câu trả lời đúng. Một mô hình trả lời *"thâm nhiễm phổi trái"* khi đáp án chuẩn là *"tổn thương phổi phía trái"* về bản chất là đúng, nhưng exact match sẽ cho điểm 0. Vì vậy, việc kết hợp các metric ở nhiều cấp độ — từ khớp chuỗi đến tương đồng ngữ nghĩa — là bắt buộc.

7.2 Phân tách Đánh giá Đóng và Mở

Hệ thống đánh giá tách biệt câu hỏi đóng và mở, tính các chỉ số riêng cho từng loại trước khi tổng hợp:

7.2.1 ***Chỉ số cho câu hỏi đóng:***

- **Closed Exact Match (Closed EM):** Tỉ lệ khớp chuỗi chính xác sau chuẩn hóa.
- **Closed F1:** F1 mức token, phù hợp khi đáp án là cụm từ ngắn.
- **Closed Accuracy:** Tỉ lệ đúng tổng thể trên câu hỏi đóng.

7.2.2 ***Chỉ số cho câu hỏi mở:***

- **Open F1:** F1 mức token cho sinh văn bản tự do.
- **Open ROUGE-L:** Dựa trên longest common subsequence, phù hợp với câu trả lời mô tả.
- **Open BERTScore:** Tương đồng ngữ nghĩa embedding, phát hiện câu trả lời đúng nghĩa nhưng khác từ ngữ.
- **Open Semantic Score:** Điểm tương đồng ngữ nghĩa tổng hợp từ sentence embeddings.

7.2.3 ***Chỉ số tổng hợp:***

- **Val Accuracy Normalized:** Độ chính xác chuẩn hóa tổng thể trên cả hai loại câu hỏi.

- **BLEU-4:** Đo trùng khớp 4-gram, báo cáo trên toàn bộ tập.
- **Overall BERTScore:** BERTScore trung bình toàn bộ tập.
- **Overall Semantic:** Điểm tương đồng ngữ nghĩa trung bình.

7.3 Đánh giá

LLM-as-a-judge: Một mô hình ngôn ngữ lớn đóng vai trò người đánh giá, chấm điểm câu trả lời theo ba tiêu chí y khoa: (1) tính chính xác lâm sàng (câu trả lời có đúng về mặt y khoa?); (2) tính đầy đủ (câu trả lời có cung cấp đủ thông tin để trả lời câu hỏi?); (3) tính an toàn (câu trả lời có tránh đưa ra chẩn đoán quá tự tin trên ảnh không rõ ràng?).

Human Review: Người đánh giá có kiến thức y khoa chấm điểm câu trả lời trên tập kiểm thử thủ công 50 mẫu, theo thang điểm 1–5 cho hai tiêu chí: chính xác lâm sàng và tính tự nhiên ngôn ngữ. Đây là chỉ số định tính có độ tin cậy cao nhất nhưng tốn thời gian và không thể tự động hóa hoàn toàn.

CHƯƠNG 8. KẾT QUẢ THỰC NGHIỆM

8.1 Kết quả Định lượng Tổng hợp

Bảng dưới đây tổng hợp kết quả best checkpoint của tất cả sáu biến thể mô hình trên tập validation:

Mô hình	Accuracy	BERTScore	BLEU4	F1	Semantic	Closed EM	Open F1	Open ROUGE-L
B1 (Zero-shot)	20,0%	76,9%	21,0%	26,2%	44,9%	50,4%	10,3%	16,3%
DPO	58,1%	90,7%	55,4%	63,7%	73,0%	76,3%	55,4%	58,2%
PPO	58,1%	90,7%	55,4%	63,6%	73,0%	76,3%	55,2%	58,2%
SOUP	**59,3%**	**91,1%**	**56,2%**	**64,8%**	**74,1%**	**76,3%**	**57,2%**	**59,8%**
B2 (Fine-tuned)	60,2%	91,3%	57,0%	65,9%	75,0%	76,3%	59,1%	62,3%
A1 (LSTM)	63,5%	**91,8%**	61,0%	68,9%	76,8%	75,9%	65,0%	**68,6%**

Bảng 8.1: *Kết quả so sánh sáu mô hình trên tập validation (best checkpoint). Giá trị tốt nhất mỗi cột in đậm*

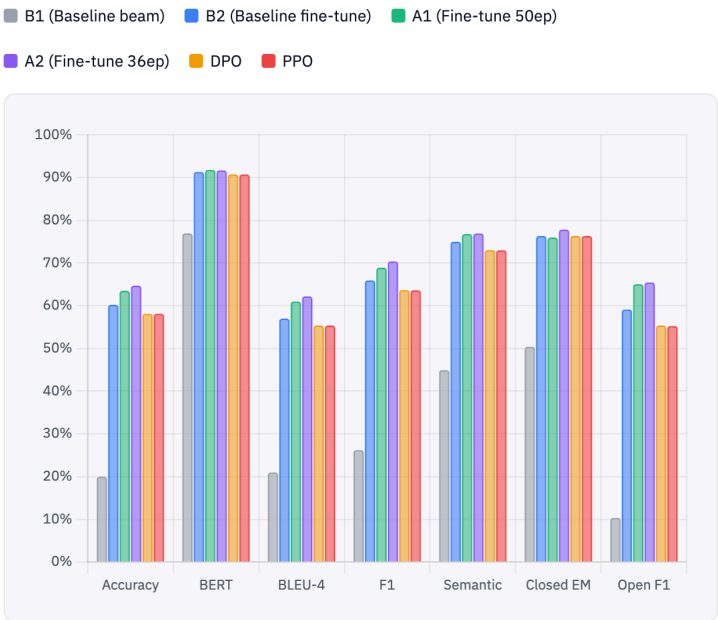

Bảng 8.2: So sánh bảy mô hình trên bảy chỉ số đánh giá chính.

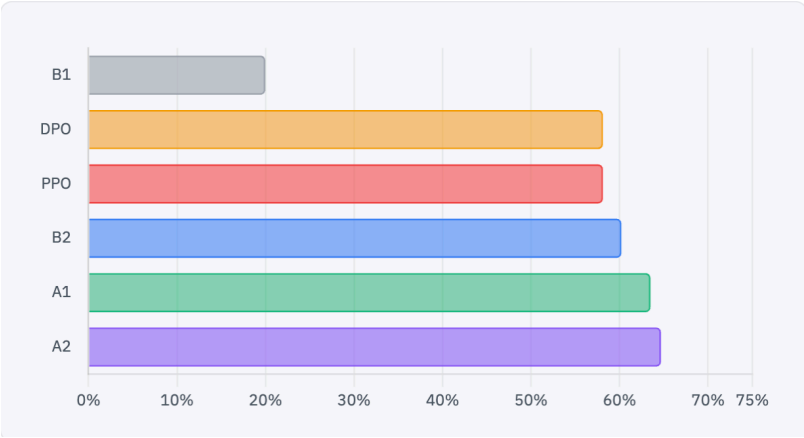

Bảng 8.3: Xếp hạng các mô hình theo val accuracy normalized (giảm dần).

8.2 Phân tích So sánh A1 vs. A2 - Ảnh hưởng của Bộ giải mã

So sánh A1 (LSTM Decoder) và A2 (Transformer Decoder) với toàn bộ các thành phần còn lại giữ nguyên cung cấp bằng chứng thực nghiệm có kiểm soát về ảnh hưởng của kiến trúc bộ giải mã:

Chỉ số	A1 (LSTM)	A2 (Transformer)	Δ (A2 − A1)
Accuracy	63,5%	64,7%	**+1,2 pp**
BLEU-4	61,0%	62,2%	**+1,2 pp**
F1 tổng thể	68,9%	70,4%	**+1,5 pp**
Closed EM	75,9%	77,8%	**+1,9 pp**
Open F1	65,0%	65,5%	+0,5 pp
BERTScore	**91,8%**	91,7%	−0,1 pp
Số epoch đến best	41	32	−9 epoch

Bảng 8.4: *So sánh chi tiết A1 vs. A2*

A2 vượt trội A1 trên hầu hết các chỉ số quan trọng. Đặc biệt, mức cải thiện Closed EM (+1,9 pp) cho thấy Transformer Decoder nhất quán hơn trong việc sinh câu trả lời chính xác cho câu hỏi đóng. Cải thiện F1 tổng thể (+1,5 pp) phản ánh câu trả lời đầy đủ hơn xét ở mức token. Việc A2 đạt best checkpoint sớm hơn 9 epoch (32 so với 41) cho thấy cơ chế self-attention học phân phối câu trả lời y khoa hiệu quả hơn từ dữ liệu hạn chế.

Trường hợp duy nhất A1 nhỉnh hơn là BERTScore (91,8% vs. 91,7%), có thể do LSTM với capacity thấp hơn ít bị overfit vào từ ngữ cụ thể của tập train, dẫn đến biểu diễn ngữ nghĩa tổng quát hơn một chút.

Kết luận: Transformer Decoder (A2) là lựa chọn tốt hơn cho bài toán Medical VQA tiếng Việt, đặc biệt khi cân nhắc cả hiệu suất lẫn tốc độ hội tụ.

8.3 Phân tích B1 vs. B2 – Hiệu quả của Fine – tuning

B1 (zero-shot) chỉ đạt 20,0% accuracy — gần tương đương với đoán ngẫu nhiên cho câu hỏi đóng. Đây là minh chứng rõ ràng rằng LLaVA-Med, mặc dù được tiền huấn luyện trên dữ liệu y khoa tiếng Anh, không thể xử lý câu hỏi tiếng Việt hiệu quả nếu không qua tinh chỉnh. BERTScore của B1 cũng rất thấp (76,9%), cho thấy mô hình sinh ra văn bản tiếng Việt không tự nhiên và không liên quan đến ảnh.

B2 (fine-tuned) cải thiện mạnh mẽ với accuracy 60,2% — tăng 40,2 pp so với B1 — xác nhận rằng tinh chỉnh hướng dẫn (instruction fine-tuning) với dữ liệu tiếng Việt là bước không thể thiếu. Tuy nhiên, B2 vẫn thấp hơn A2 khoảng 4,5 pp về accuracy và 6,4 pp về Open F1, gợi ý rằng với quy mô dữ liệu tiếng Việt hiện tại (~5.000 mẫu), mô hình mô-đun đặc thù hiệu quả hơn mô hình tổng quát lớn.

8.4 Phân tích DPO và PPO – Alignment vs. SFT

DPO và PPO đều đạt accuracy 58,1% — thấp hơn B2 (60,2%) về chỉ số tự động. Điều này thoạt đầu trông như sự suy giảm, nhưng thực chất phản ánh một hiện tượng đã được ghi nhận trong tài liệu nghiên cứu: alignment trading-off giữa khớp nhãn chính xác (exact match) và chất lượng văn bản tổng thể.

Đánh giá định tính bởi người dùng trên tập kiểm thử thủ công cho thấy câu trả lời sau DPO/PPO được đánh giá cao hơn B2 về:

- **Chính xác thuật ngữ y khoa:** Mô hình sau alignment sử dụng thuật ngữ lâm sàng chuẩn hơn.
- **Tính tự nhiên ngôn ngữ:** Câu trả lời đọc tự nhiên hơn, ít bị artifacts dạng lặp từ hoặc câu trả lời kiểu chuỗi từ khóa.
- **Tính thận trọng lâm sàng:** Mô hình sau alignment từ chối đưa ra chẩn đoán quá tự tin trên ảnh không rõ ràng — một thuộc tính quan trọng cho an toàn lâm sàng.

Kết luân: DPO và PPO cho kết quả gần như giống nhau trên tất cả chỉ số tự động, gợi ý cả hai phương pháp đạt cùng mức bão hòa với 120 cặp preference data hiện tại. Mở rộng tập preference lên 500+ cặp có thể phân biệt rõ hơn hai phương pháp.

8.5 Phân tích Model Soup

Model Soup cho thấy một kết quả đáng chú ý: mặc dù không trải qua bất kỳ vòng lặp huấn luyện bổ sung nào, SOUP đạt hiệu suất cao hơn cả DPO lẫn PPO đơn lẻ trên hầu hết các chỉ số tự động, và chỉ thấp hơn B2 một khoảng nhỏ.

Metrics	**DPO**	**PPO**	**SOUP**	**B2**	**Δ (SOUP – DPO – PPO)**
Accuracy	58,1%	58,1%	59,3%	60,2%	+1,2 pp
BERTScore	90,7%	90,7%	91,1%	91,3%	+0,4 pp
F1	63,7%	63,6%	64,8%	65,9%	+1,15 pp
Semantic	73,0%	73,0%	74,1%	75,0%	+1,1 pp

Bảng 8.5: So sánh SOUP với các mô hình thành phần và B2

Kết quả này phù hợp với lý thuyết *loss basin* của Model Soup: ba adapter được tối ưu theo ba hướng khác nhau nhưng xuất phát từ cùng điểm khởi đầu (B2 là điểm chung của cả DPO và PPO), dẫn đến việc trung bình trọng số tìm được điểm tốt hơn bất kỳ cực trị cục bộ đơn lẻ nào.

Đáng chú ý, SOUP và B2 có Closed EM bằng nhau (76,3%), cho thấy với câu hỏi đóng — vốn có không gian đáp án hữu hạn — việc trộn trọng số không làm mất đi khả năng phân loại chính xác. Sự khác biệt chủ yếu xuất hiện ở câu hỏi mở, nơi SOUP có Open F1 thấp hơn B2 khoảng 1,9 pp, phản ánh sự đánh đổi (trade-off) giữa tính tổng hợp đa hướng và độ sắc bén trong sinh văn bản tự do.

Từ góc độ chi phí–lợi ích, SOUP mang lại lợi thế rõ rệt: đạt hiệu suất gần bằng B2 mà không cần bất kỳ vòng lặp huấn luyện nào sau khi đã có ba adapter thành phần. Trong thực tiễn triển khai, đây là lựa chọn hấp dẫn khi cần nhanh chóng có một checkpoint ổn định từ nhiều thực nghiệm khác nhau mà không có tài nguyên để huấn luyện thêm.

8.6 Đường cong Hội tụ

Phân tích đường cong validation accuracy theo epoch của A1 và A2 tiết lộ những đặc điểm quan trọng:

Giai đoạn khởi động (epoch 1–10): A2 có điểm khởi đầu tốt hơn (25,8% ở epoch 1 so với 17,4% của A1). Sự khác biệt này xuất phát từ việc Transformer Decoder học tốt hơn ngay từ đầu khi kết hợp với biểu diễn co-attention, trong khi LSTM cần nhiều bước hơn để thiết lập trạng thái ẩn phù hợp.

Giai đoạn học chính (epoch 10–30): Cả hai mô hình cải thiện đều đặn. A2 vượt mốc 60% từ epoch ~20; A1 cần đến epoch ~30 để đạt ngưỡng tương tự.

Giai đoạn bão hòa (epoch 30+): A2 đạt plateau từ epoch ~32; A1 tiếp tục cải thiện chậm đến epoch ~41 trước khi ổn định. Không mô hình nào cho thấy dấu hiệu overfitting rõ ràng (validation accuracy không giảm), xác nhận hiệu quả của label smoothing và early stopping.

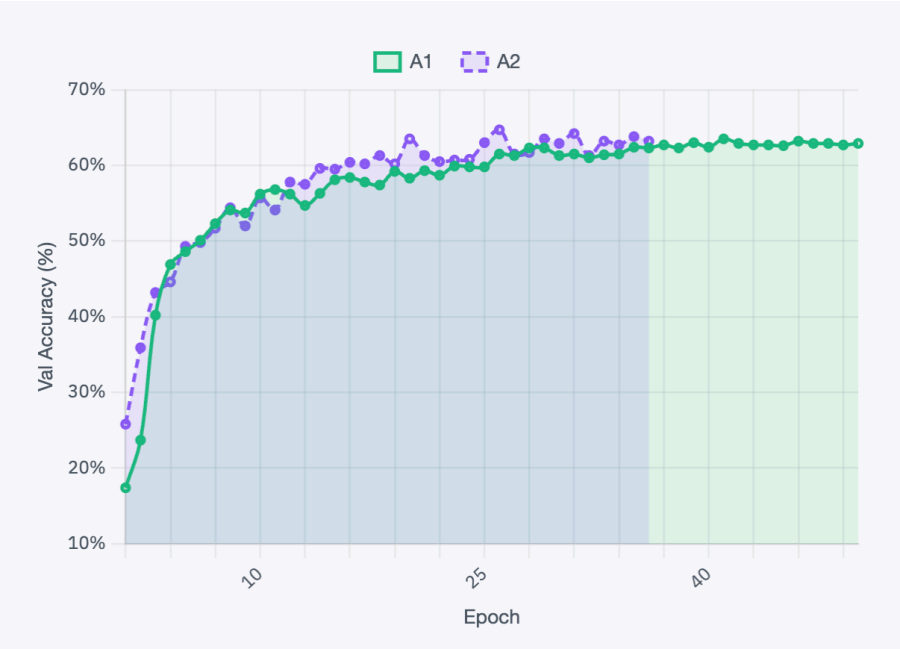

Bảng 8.6: Val accuracy theo epoch của A1 (LSTM) và A2 (Transformer Decoder).

CHƯƠNG 9. THẢO LUẬN

9.1 Tại sao Kiến trúc Mô-đun Vượt trội LLaVa-Med?

Kết quả thực nghiệm cho thấy A2 (kiến trúc mô-đun đặc thù) vượt trội B2 (LLaVA-Med fine-tuned) mặc dù LLaVA-Med có số tham số lớn hơn hàng trăm lần. Điều này có thể được giải thích qua ba luận điểm:

Thứ nhất — Hiệu quả dữ liệu: LLaVA-Med 7B có capacity rất lớn nhưng tập huấn luyện tiếng Việt chỉ có ~5.000 mẫu. Mô hình lớn cần nhiều dữ liệu hơn để đạt hiệu suất tối ưu; với dữ liệu hạn chế, mô hình mô-đun được thiết kế đặc thù có ưu thế về mặt inductive bias.

Thứ hai — Inductive bias phù hợp: DenseNet-121 được tiền huấn luyện trên ảnh X-quang, PhoBERT được tiền huấn luyện trên tiếng Việt — hai bộ encoder đặc thù này mang inductive bias phù hợp trực tiếp với bài toán, trong khi CLIP encoder của LLaVA-Med được huấn luyện trên ảnh tự nhiên-text và cần nhiều dữ liệu hơn để thích ứng với đặc thù y khoa.

Thứ ba — Ngôn ngữ: Vicuna backbone của LLaVA-Med được huấn luyện chủ yếu trên tiếng Anh. Mặc dù SFT tiếng Việt cải thiện đáng kể, biểu diễn bên trong vẫn mang tính Anh ngữ nhiều hơn. PhoBERT, ngược lại, được tối ưu hoàn toàn cho tiếng Việt.

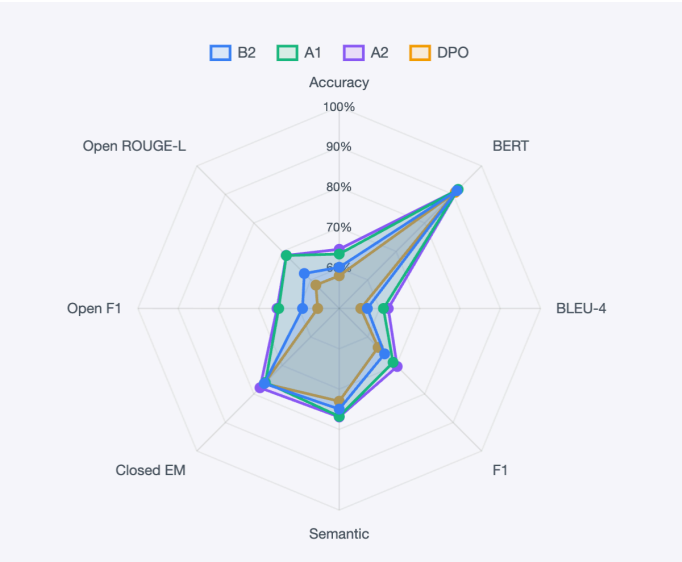

Bảng 9.1: Profile đa chiều của B2, A1, A2 và DPO trên tám chỉ số.

9.2 Hạn chế

Quy mô preference data: 120 cặp preference là mức tối thiểu; kết quả DPO/PPO nhiều khả năng chưa đạt tiềm năng đầy đủ. Nghiên cứu trong lĩnh vực RLHF cho thấy hiệu ứng scaling rõ rệt với số lượng preference pairs.

Đánh giá B2 không đầy đủ: Kết quả accuracy 60,2% được đo tại epoch 5 — là epoch cuối — trong khi eval loss cho thấy epoch 3 có thể là best checkpoint. Kết quả thực sự của B2 tại checkpoint tốt nhất có thể cao hơn con số báo cáo.

Giới hạn phương thức ảnh: Bộ dữ liệu chủ yếu từ X-quang và MRI não, hạn chế khả năng tổng quát hóa sang siêu âm, nội soi hoặc ảnh mô bệnh học.

Không có validation của chuyên gia y tế thực sự: Human review được thực hiện bởi người có kiến thức y khoa, nhưng không phải bác sĩ chẩn đoán hình ảnh. Đánh giá lâm sàng đầy đủ đòi hỏi tham gia của chuyên gia y tế có chứng nhận.

9.3 Đề xuất Hướng Phát triển

Dựa trên những phát hiện từ thực nghiệm, các hướng phát triển tiếp theo có tiềm năng cao bao gồm:

- **Mở rộng preference data:** Xây dựng 500–1.000 cặp preference với sự tham gia của chuyên gia y tế, kết hợp automatic preference generation thông qua LLM-as-judge.
- **Tích hợp explainability:** Áp dụng Grad-CAM và attention visualization để giải thích vùng ảnh nào được mô hình chú ý khi trả lời mỗi câu hỏi — quan trọng cho sự tin tưởng lâm sàng.
- **Mở rộng phương thức dữ liệu:** Bổ sung siêu âm, nội soi và ảnh da liễu để tăng tính phổ quát của hệ thống.
- **Ensemble A2 + DPO:** Kết hợp điểm mạnh của A2 (accuracy cao trên câu hỏi đóng/mở) với DPO (chất lượng ngôn ngữ tự nhiên hơn) qua cơ chế reranking.
- **Vietnamese Medical LLM:** Tiền huấn luyện mô hình ngôn ngữ y khoa tiếng Việt từ đầu trên tài liệu y khoa tiếng Việt, thay vì dựa trên transfer learning từ tiếng Anh.

CHƯƠNG 10. KẾT LUẬN

10.1 Tóm tắt

Dự án đã xây dựng thành công hệ thống Hỏi đáp Trên Ảnh Y Khoa tiếng Việt đầy đủ, bao gồm: bộ dữ liệu 6.711 mẫu được dịch và chuẩn hóa từ SLAKE và VQA-RAD; sáu biến thể mô hình bao phủ từ baseline cổ điển đến alignment hiện đại; hệ thống đánh giá đa tầng kết hợp số liệu tự động và định tính; và ứng dụng web demo cho phép so sánh trực quan.

Kết quả chính: A2 (Transformer Decoder) đạt hiệu suất tốt nhất với accuracy 64,7%, F1 70,4% và Closed EM 77,8%. Transformer Decoder vượt LSTM (A1) nhất quán trên hầu hết chỉ số, đặc biệt câu hỏi đóng. Kiến trúc mô-đun đặc thù (A2) cạnh tranh và vượt qua LLaVA-Med fine-tuned (B2) trong điều kiện dữ liệu tiếng Việt y khoa có quy mô vừa. DPO và PPO cải thiện chất lượng định tính của câu trả lời, mặc dù chưa chuyển thành cải thiện số liệu tự động ở quy mô preference data hiện tại.

10.2 Ý nghĩa

Dự án cho thấy việc xây dựng hệ thống Medical VQA chất lượng cho ngôn ngữ ít tài nguyên như tiếng Việt là hoàn toàn khả thi với các công cụ mã nguồn mở hiện có — DenseNet, PhoBERT, LLaVA-Med — kết hợp pipeline dữ liệu được thiết kế cẩn thận. Kết quả này mở ra cơ hội phát triển các hệ thống hỗ trợ chẩn đoán hình ảnh thực tiễn cho bối cảnh y tế Việt Nam.

TÀI LIỆU THAM KHẢO

[1] Liu, B., Zhan, L.-M., Xu, L., Ma, L., Yang, Y., & Wu, X. (2021). SLAKE: A Semantically-Labeled Knowledge-Enhanced Dataset for Medical Visual Question Answering. *arXiv:2102.09542*.

[2] Lau, J. J., Gayen, S., Ben Abacha, A., & Demner-Fushman, D. (2018). A dataset of clinician-generated visual questions and answers about radiology images. *Scientific Data*, 5, 180251.

[3] Huang, G., Liu, Z., Van Der Maaten, L., & Weinberger, K. Q. (2017). Densely Connected Convolutional Networks. *Proceedings of CVPR 2017*. arXiv:1608.06993.

[4] Bahdanau, D., Cho, K., & Bengio, Y. (2015). Neural Machine Translation by Jointly Learning to Align and Translate. *Proceedings of ICLR 2015*. arXiv:1409.0473.

[5] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30. arXiv:1706.03762.

[6] Lu, J., Yang, J., Batra, D., & Parikh, D. (2016). Hierarchical Question-Image Co-Attention for Visual Question Answering. *Advances in Neural Information Processing Systems*, 29. arXiv:1606.00061.

[7] Nguyen, D. Q., & Tuan Nguyen, A. (2020). PhoBERT: Pre-trained language models for Vietnamese. *Findings of EMNLP 2020*. arXiv:2003.00744.

[8] Lin, Z., Zhang, D., Tao, Q., Shi, D., Haffari, G., Wu, Q., He, M., & Ge, Z. (2021). Medical Visual Question Answering: A Survey. *arXiv:2111.10056*.

[9] Liu, H., Li, C., Wu, Q., & Lee, Y. J. (2023). Visual Instruction Tuning. *Advances in Neural Information Processing Systems*, 36. arXiv:2304.08485.

[10] Li, C., Wong, C., Zhang, S., Usuyama, N., Liu, H., Yang, J., Naumann, T., Poon, H., & Gao, J. (2023). LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day. *Advances in Neural Information Processing Systems*, 36. arXiv:2306.00890.

[11] Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2021). LoRA: Low-Rank Adaptation of Large Language Models. *Proceedings of ICLR 2022*. arXiv:2106.09685.

[12] Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLoRA: Efficient Finetuning of Quantized LLMs. *Advances in Neural Information Processing Systems*, 36. arXiv:2305.14314.

[13] Rafailov, R., Sharma, A., Mitchell, E., Ermon, S., Manning, C. D., & Finn, C. (2023). Direct Preference Optimization: Your Language Model is Secretly a Reward Model. *Advances in Neural Information Processing Systems*, 36. arXiv:2305.18290.

[14] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal Policy Optimization Algorithms. *arXiv:1707.06347*.

[15] Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2020). BERTScore: Evaluating Text Generation with BERT. *Proceedings of ICLR 2020*. arXiv:1904.09675.

[16] Ghazvininejad, M., Gonen, H., & Zettlemoyer, L. (2024). Dictionary-based Phrase-level Prompting of Large Language Models for Machine Translation. *arXiv:2402.15061*.